

**2.1** Wygeneruj chmurę punktów w następujący sposób. Niech  $x_i$  będą punktami z zakresu  $[0, 10]$  odległymi o 0.1, natomiast  $y_i = x_i + \epsilon_i$ , gdzie  $\epsilon_i$  to zmienne losowe z rozkładu normalnego o średniej 0 i odchyleniu standardowym  $\sigma = 3$ . Wykonaj wykres rozproszenia  $(x_i, y_i)$ .

- (a) Oblicz współczynnik korelacji próbkowej korzystając z definicji oraz funkcji `cor()` w pakiecie R.
- (b) Oblicz współczynniki prostej MNK korzystając z definicji oraz funkcji `lm()` w pakiecie R.
- (c) Nanieś otrzymaną prostą MNK na wykres rozproszenia.
- (d) Powtórz procedurę z punktów (a)-(c) dla  $\sigma = 0.5$ ,  $\sigma = 5$ . Co możemy powiedzieć o wartości współczynnika korelacji próbkowej oraz współczynnikach prostej MNK?

**2.2** W pakiecie R w bibliotece MASS znajduje się zbiór danych *hills* dotyczących biegów przełajowych, które odbyły się w Szkocji w 1984 roku. Zawiera on trzy zmienne:

*time* - rekordowy czas pokonania trasy (w minutach),

*dist* - długość trasy w milach (na mapie),

*climb* - całkowita różnica poziomów do pokonania na trasie (w stopach).

(a) Porównaj (wyświetlając w jednym oknie) wykresy rozproszenia *time* od *dist* i *time* od *climb*. Oblicz współczynniki korelacji *time* i *dist* oraz *time* i *climb*.

(b) Dopasuj proste MNK opisujące zależność *time* od *dist* oraz *time* od *climb*. Nanieś dopasowane proste na wykresy rozproszenia. Oblicz  $R^2$  dla otrzymanych modeli posługując się dwiema metodami:

- z definicji, wyznaczając wartości SST, SSR i SSE,
- korzystając z funkcji `summary()`.

(c) Jaki rekordowy czas pokonania trasy o długości 15 mil przewidzimy posługując się prostą MNK?

**2.3** Wczytaj i wyświetl na ekranie zbiór *anscombe\_quartet.txt*.

(a) Do każdej z czterech par zmiennych dopasuj prostą MNK.

(b) Porównaj otrzymane współczynniki dopasowanych prostych MNK, współczynniki  $R^2$  i współczynniki korelacji.

(c) W jednym oknie narysuj 4 wykresy rozrzutu  $Y_i$  od  $X_i$ ,  $i = 1, 2, 3, 4$ . W którym przypadku możemy mówić o przybliżonej zależności liniowej  $y$  od  $x$ ?

**2.4** Wygeneruj dane w następujący sposób:

$$y_i = \beta_0 + \beta_1 x_{i,1} + \beta_2 x_{i,2} + \beta_3 x_{i,3} + \epsilon_i,$$

gdzie  $\beta_0 = 0.5$ ,  $\beta_1 = 1$ ,  $\beta_2 = 0.5$ ,  $\beta_3 = 0.75$ . Niech  $x_{i,1}, x_{i,2}, x_{i,3} \sim N(0, 1)$  i  $\epsilon_i \sim N(0, 1)$ .

- a) Wygeneruj zbiór danych dla  $n = 100$  obserwacji.
- b) Wyznacz macierz eksperymentu.
- c) Wyznacz rozkład QR macierzy eksperymentu.
- d) Udowodnij, że  $R\hat{\beta} = Q'y$ .
- e) Używając powyższego równania wyznacz wartość estymatora wektora współczynników  $\beta = [\beta_0, \beta_1, \beta_2, \beta_3]$